

PROPOSAL DEFENSE

Mutation Testing • LLM • Java

GPT-4o mini-based Mutant Selection for Java Mutation Testing

So sánh trực tiếp với random fixed-seed selection dưới cùng top 10% mutant budget

Defects4J + PIT

Wilcoxon

$\alpha = 0.05$

4 tuần

Nhóm 3

Phạm Mạnh Quỳnh · Phan Nguyễn Đình Khôi · Nguyễn Nhật Anh · Nguyễn Trường Vinh · Trần Trúc Vy

Research Proposal • Version 1.0

1. Vấn đề nghiên cứu và khoảng trống

Từ chi phí mutation testing đến câu hỏi “LLM có thực sự chọn mutant tốt hơn random?”

Bối cảnh

Mutation testing tạo nhiều biến thể lỗi nhỏ để đánh giá test suite.

Vấn đề: số mutant lớn → chi phí thực thi cao → khó áp dụng ở quy mô thực tế.

Những gì đã có

- LLM cho mutant generation / filtering
- ML/DL cho predictive mutation testing
- Learning-based mutant reduction
- Random vẫn là baseline phổ biến

GAP-T / GAP-M

Chưa có đánh giá trực tiếp GPT-4o mini như “decision-maker” chọn subset mutant hữu ích so với random fixed-seed dưới cùng budget và cùng mutation score.

MOTIVATION

Nếu không đặt GPT-4o mini và random vào cùng điều kiện kiểm soát, nhóm không thể biết chi phí API có tạo ra lợi ích thực sự hay không.

2. Evidence landscape

Các nghiên cứu liên quan hỗ trợ từng mắt xích của proposal

1

LLM generation / filtering

Wang et al.; SMART; GEM-LLM

Đã chứng minh LLM hữu ích trong mutation testing, nhưng chưa đánh giá subset selection trực tiếp.

2

Predictive mutation testing

SODA; MutationBERT; Seshat

Tập trung dự đoán killed/survived hoặc kill matrix, không phải GPT-4o mini ranking.

3

Selective mutation

LEAM++

Khẳng định hướng giảm số mutant là hợp lý và có giá trị.

4

Ranking vs random

Jimenez et al.; PRIMG

Cung cấp pattern so sánh selection/prioritization với random baseline.

Synthesis → prior work supports the components, but the exact controlled comparison remains insufficiently evaluated.

3. Research Question, giả thuyết và tiêu chí thành công

Slide trọng tâm: claim phải khớp metric, threshold và statistical test

RQ1 Trên Defects4J Java projects, GPT-4o mini-based mutant selection có đạt mutation score cao hơn random fixed-seed selection khi cả hai chọn top 10% mutants không?

H0

$MS_{GPT4o} \leq MS_{random}$

GPT-4o mini không tốt hơn random.

H1

$MS_{GPT4o} > MS_{random}$

GPT-4o mini chọn subset hiệu quả hơn.

Metric

Mutation Score = Killed / Selected

Paired theo project / version / class.

SUCCESS CRITERIA

$p < 0.05$

$r_{rb} \geq 0.30$


$\text{median}(\Delta MS) > 0$

Chỉ kết luận ủng hộ H1 khi cả 3 điều kiện cùng đạt.

Budget source gần nhất: AL-PMT (10% observed kill status). Đây là nguồn budget tham khảo, không phải ngưỡng đã được chứng minh cho LLM selection.

4. Experimental pipeline

Một mutant pool, hai chiến lược selection, cùng budget và cùng cách đo



CONTROLLED COMPARISON

- Cùng mutant pool và cùng PIT configuration
- Cùng số lượng mutant được chọn
- Log prompt, model, output, selected IDs và API cost
- Ground truth lấy từ PIT execution, không dùng LLM explanation

5. Dataset, công cụ và baseline

Phạm vi vừa đủ cho pilot 4 tuần nhưng vẫn tái lập được

Dataset

DEFECTS4J

- Java benchmark công khai
- Dự kiến: Commons Lang + Commons Math
- Chỉ giữ version/class build và test thành công
- Ground truth: PIT killed/survived

Tooling

PIT (Pitest)

- Generate mutants
- Maven integration
- Mutation report

Execution:

Kaggle Notebook / OpenJDK / Maven
Chia theo class/version nếu session > 12h

Baseline

RANDOM FIXED-SEED

- Cùng mutant pool
- Cùng top 10% budget
- Seed chính: 42
- Optional: 123, 2026
- Đơn giản, công bằng, tái lập

Input features cho GPT-4o mini

mutant ID • operator • original code • mutated code • surrounding context

6. Statistical analysis plan

Tách rõ statistical significance và practical significance

Paired data

- Đơn vị: project / version / class
- Cặp giá trị: MS_GPT4o và MS_random
- $\Delta MS = MS_GPT4o - MS_random$
- Không giả định phân phối chuẩn

One-sided Wilcoxon

$\alpha = 0.05$

Effect size

Matched-pairs rank-biserial correlation

$$r_{rb} \geq 0.30$$

Ngưỡng medium effect để tránh kết luận quá mạnh khi khác biệt chỉ nhỏ về mặt thực tế.

Decision rules

Ủng hộ H1

$p < .05$ & $r \geq .30$ & $\text{median}\Delta > 0$

Có khác biệt, nhỏ

$p < .05$ nhưng $r < .30$

Xu hướng dương

$\Delta > 0$ nhưng $p \geq .05$

Không hơn random

$\Delta \leq 0$

Nếu số cặp quá ít → báo cáo descriptive comparison trước, không over-claim.

7. Threats to validity và cách giảm thiểu

Mỗi threat được gắn trực tiếp với một control trong protocol

Internal	Model drift / unfair comparison	Pin model, temperature=0; cùng pool và budget
External	Chỉ Lang + Math; phụ thuộc PIT	Giới hạn claim; log tool/version/config
Construct	Mutation score và equivalent mutants	Cùng metric cho hai nhánh; báo killed/survived; ghi limitation
Conclusion	Sample nhỏ; random variability	Descriptive nếu n nhỏ; optional multi-seed; không HARKing
HARKing prevention: metric, threshold, test và subgroup được chốt trước khi chạy experiment.		

8. Timeline, nguồn lực và contingency

Kế hoạch 4 tuần sau khi proposal được duyệt



Nguồn lực

- Defects4J + PIT: \$0
- Kaggle / local Maven: \$0
- GPT-4o mini API
- Python + SciPy
- 5 thành viên, role tách biệt

Chi phí dự kiến

\$1–3 cho pilot downscope

2,000–5,000 mutants
+ 20% rerun buffer

Chi phí thật sẽ log theo token.

Contingency

PIT lâu → giảm class/version
API lỗi → giảm context / batch
Không đủ pairs → descriptive
GPT không hơn random → negative finding hợp lệ

Deliverables: mutant_pool.csv • llm_output.csv • analysis.ipynb • result table

9. Đóng góp dự kiến

Giá trị của nghiên cứu vẫn tồn tại dù kết quả dương hay âm

Đóng góp thực nghiệm

So sánh trực tiếp GPT-4o mini ranking với random fixed-seed trong cùng điều kiện kiểm soát.

Đóng góp phương pháp

Pipeline tái lập: fixed prompt, pinned model, same budget, selected IDs, seed và statistical plan.

Đóng góp thực tiễn

Cung cấp bằng chứng để quyết định có nên trả chi phí API cho mutant selection hay dùng baseline đơn giản.

Positive result → evidence of value | Negative result → documented limitation and future-work direction

Q&A

Cảm ơn thầy/cô và các bạn đã lắng nghe
